

Data Mining — Project Part 1

דוח איסוף נתוני סרטים

שם	תעודת זהות
ניר אברהמוף	209413053
איתמר רוט	211994025

1. סקירה כללית

דוח זה מתאר את תהליך בניית מאגר נתוני סרטים כחלק ממטלה 1 בקורס כריית נתונים. המאגר כולל 5,000 סרטים שכותרתם מתחילה באות Q או R, ונבנה בארבעה שלבים עיקריים: טעינת נתונים ממאגרי IMDb, הציבוריים, סינון לפי קריטריוני המטלה, השלמת נתונים חסרים דרך Wikipedia ו-OMDb API, וניקוי וייצוא סופי.

2. החלטות שנלקחו בבניית סט הנתונים

סינון לפי אות ראשונה

על פי הנחיות המטלה, נבחרו אך ורק סרטים שכותרתם (primaryTitle) מתחילה באות Q או R. הסינון בוצע כך שלא משנה אם האות גדולה או קטנה, באמצעות `str.match(r'^[QRqr]')`. לאחר כל הסינונים נותרו 13,329 סרטים מתאימים.

קריטריוני סינון נוספים

בנוסף לאות הראשונה, הוחלו שלושה פילטרים: `titleType == 'movie'` בלבד, שנת יציאה עד 2024 (`startYear <= 2024`), ומשך סרט בין 60 ל-300 דקות (`runtimeMinutes`).

מיון לפי פופולריות ובחירת 5,000 הסרטים

מתוך 13,329 הסרטים שעברו את הסינון, מוינו הסרטים בסדר יורד לפי `numVotes` (מספר המדרגים ב-IMDb), ונבחרו 5,000 הראשונים — כדי להבטיח שהדאטאסט יכלול את הסרטים הפופולריים והמוכרים ביותר.

טעינת `title.principals` בחתיכות (chunks)

קובץ ה-`principals` של IMDb שוקל מספר ג'יגה-בייט. כדי למנוע חריגת זיכרון, הקובץ נקרא ב-`chunks` של 500,000 שורות, עם סינון מיידי בכל `chunk` — כך נשמרו רק הרשומות הרלוונטיות לסרטי ה-Q/R.

הכללת `actor` ו-`actress` ב-`lead_actors_ids`

השדה כולל גם `actor` וגם `actress` מתוך עמודת ה-`category` ב-`principals`. בחרנו לכלול שניהם מכיוון שבעברית המונח "שחקנים" כולל שני המינים, ובפועל הרבה סרטים כוללות שחקניות ראשיות. נלקחו עד 5 שחקנים לפי סדר קרדיט (`ordering`).

היררכיה בין מקורות הנתונים

עבור 1,000 הסרטים הראשונים, OMDb שימש כמקור ראשי ל-`Country`, `Language` ו-`plot`, בעוד Wikipedia נוצל תמיד לנתוני תקציב וקופות — מכיוון ש-OMDb מחזיר לרוב ערך חסר או חלקי עבור שדות אלו, ואילו Wikipedia מכיל infobox מפורט הכולל מטבע מקורי, טווחים ועדכונים. במקרה ש-OMDb נכשל, Wikipedia שימש כגיבוי מלא. מסרט 1,001 ואילך, Wikipedia היה המקור היחיד לשדות `Country`, `Language`, `budget` ו-`BoxOffice` ו-`plot`. שאר השדות נלקחו כרגיל ממאגרי IMDb.

ניקוי נתונים פיננסיים עם המרת מטבע

הפונקציה `clean_financial_data` מטפלת בפורמטים מגוונים: סמלי מטבע (£, €, ₹, ¥ ועוד +30 מטבעות), טווחי ערכים ("1 to 2 million"), וקיצורים (million, billion, crore, lakh). הכל מומר לדולר אמריקאי ומנומלל ליחידות של מיליוני USD.

אימות שנה בגריפת Wikipedia

כדי למנוע התאמה לסרט שגוי, הסקריפט בודק שה-infobox של הדף מכיל את שנת הסרט (±1 שנה), שכן תאריכי פרמיירה ויציאה לקולנוע עשויים להיות שונים. דפי disambiguation מסוננים אוטומטית.

שמירת checkpoints

במהלך לולאת האיסוף נשמר קובץ גיבוי (`dataset_raw_checkpoint.csv`) כל 500 סרטים — כדי למנוע אובדן נתונים במקרה של ניתוק רשת בעת ריצה ממושכת.

חשיפת ה-API Key

מפתח OMDb API נשאר גלוי בקוד בכוונה, על מנת שהשותף לפרויקט והמורים יוכלו לשחזר את התוצאות במלואן. המפתח ייעודי לפרויקט לימודי זה בלבד.

3. תיאור השדות בדאטאסט

הדאטאסט הסופי כולל 13 עמודות. הטבלה הבאה מתארת כל שדה, טיפוסו ומקורו:

שדה	טיפוס	מקור	תיאור
tconst	string	IMDb	מזהה ייחודי של הסרט ב-IMDb (לדוגמה: tt0111161)
primaryTitle	string	IMDb	כותרת הסרט הרשמית — מתחילה ב-Q או R
startYear	Int64	IMDb	שנת יציאת הסרט (1913-2024)
genres	list	IMDb	רשימת ז'אנרים (עד 3), לדוגמה: ['Drama', 'Crime']
lead_actors_ids	list	IMDb	מזהי nconst של עד 5 שחקנים/ות ראשיים לפי סדר קרדיט
runtimeMinutes	Int64	IMDb	משך הסרט בדקות (60-300)
averageRating	float	IMDb	ציון ממוצע של משתמשי IMDb בסולם 0-10
Language	string	OMDb / Wikipedia	שפת הסרט הראשית (או מספר שפות מופרדות בפסיק)
Country	string	OMDb / Wikipedia	מדינת/ות ייצור הסרט
numVotes	Int64	IMDb	מספר מדרגים ב-IMDb — שימש גם למיון לבחירת 5,000
budget	float	Wikipedia	תקציב הפקה במיליוני דולר (USD), לאחר המרת מטבע
BoxOffice	float	Wikipedia	הכנסות קופות במיליוני דולר (USD), לאחר המרת מטבע
plot	string	OMDb / Wikipedia	תקציר עלילת הסרט (נלקח מסעיף / Plot Synopsis / Premise)

4. מספר הסרטים שנאספו

פרמטר	ערך
סרטים לאחר כל הסינונים	13,329
סרטים בדאטאסטט הסופי (top by numVotes)	5,000
טווח שנים	2024 - 1913
ציון IMDb ממוצע	5.92
שפה נפוצה ביותר	English (1,341 סרטים)
מדינת ייצור נפוצה ביותר	United States (987 סרטים)
סרטים עם נתוני תקציב	821 (16.4%)
סרטים עם נתוני קופות	1,035 (20.7%)
סרטים שנשאבו דרך OMDb	1,000 (מגבלת גרסה חנימית)
סרטים שנשאבו דרך Wikipedia בלבד	4,000

5. ערכים חסרים לפי עמודה

הטבלה הבאה מציגה את מספר הערכים החסרים ואחוזם בכל עמודה בדאטאסטט הסופי (5,000 סרטים):

עמודה	מלאים	חסרים	אחוז חסרים	הסבר
tconst	5,000	0	0.00%	שדה חובה במאגר IMDb
primaryTitle	5,000	0	0.00%	שדה חובה במאגר IMDb
startYear	5,000	0	0.00%	שדה חובה במאגר IMDb
genres	4,992	8	0.16%	מעט סרטים ללא ז'אנר רשום ב-IMDb
lead_actors_ids	4,651	348	6.96%	סרטים ללא שחקנים מתועדים ב-principals
runtimeMinutes	5,000	0	0.00%	שדה חובה (שימש בסינון)
averageRating	5,000	0	0.00%	שדה חובה (שימש במיון)
numVotes	5,000	0	0.00%	שדה חובה (שימש במיון)
Language	2,796	2,204	44.08%	דף Wikipedia לא נמצא / OMDb לא זיהה את הסרט
Country	2,818	2,182	43.64%	דף Wikipedia לא נמצא / OMDb לא זיהה את הסרט
budget	821	4,179	83.58%	הנתון לא פורסם עבור רוב הסרטים
BoxOffice	1,035	3,964	79.28%	הנתון לא פורסם עבור רוב הסרטים
plot	2,406	2,594	51.88%	דף Wikipedia לא נמצא / OMDb לא זיהה את הסרט

פירוט

שדות ה-IMDb מלאים לחלוטין — הם שימשו כקריטריוני סינון ולכן ערכים חסרים סוננו מראש. השדות Language, Country ו-plot מציגים כ-44%-52% חסרים. הגורמים העיקריים: סרטים ישנים או קטנים שאין להם דף Wikipedia ייעודי, כתובות URL לא סטנדרטיות שהסקריפט לא

הצליח לנחש, ודפי disambiguation שסוננו בכוונה. OMDb כיסה בהצלחה את 1,000 הסרטים הפופולריים ביותר.

השדות `budget` ו-`BoxOffice` מציגים 79%-83 חסרים — זהו אחוז צפוי ומקובל בדאטאסטים מסוג זה, שכן רוב ההפקות לא מפרסמות את נתוניהן הכספיים בציבור.

6. דרישות הגשה

קבצים להגשה

תוכן נדרש	קובץ
קוד מלא של תהליך האיסוף — טעינה, סינון, גריפה, ניקוי פינגסי וייצוא	ProjectPart1.ipynb
דאטאסט סופי ומנוקה: 5,000 סרטים, 13 עמודות, קידוד UTF-8-sig	dataset.csv
נתוני גלם לפני עיבוד הנתונים הפינגסיים (<code>clean_financial_data</code>)	dataset_raw.csv
דוח זה — תיאור שדות, החלטות עיצוב ואחוזי חסרים	report.pdf
הוראות הפעלה, דרישות סביבה וקישור למאגר Git	README.md